

Опис використаної архітектури, методу навчання й інференсу

У лабораторній роботі було реалізовано Text-to-Speech систему на базі архітектури GPT2TTS. Основу моделі складає класичний Decoder-only Transformer (на базі конфігурації GPT-2, ~137 млн параметрів). Особливістю архітектури є те, що вона працює як мультимодальна мовна модель: на вхід подається конкатенована послідовність текстових токенів (розділених спеціальними токенами [Text], [BOS]) та аудіо-токенів. Для стиснення та відновлення аудіосигналу використовується нейронний аудіокодек FocalCodec. Модель використовує причинно-наслідкову маску (Causal Attention Mask), щоб кожен наступний токен залежав лише від попередніх.

Навчальний пайплайн було імплементовано за допомогою фреймворку PyTorch Lightning (клас LitTTS).

- Оптимізатор: AdamW зі швидкістю навчання (learning rate) $3e-4$ та weight_decay 0.01.
- Функція втрат: CrossEntropyLoss, що обраховує похибку передбачення наступного аудіо-токена.
- Дані: Використано сабсет датасету LJ Speech (1000 записів) для прискорення експерименту.
- Оптимізація процесу: Для запобігання перенавчанню (overfitting) та економії обчислювальних ресурсів було застосовано механізм Early Stopping. Він відслідковував метрику train_loss і був налаштований зупинити навчання, якщо показник не покращувався на 0.05 протягом 2 епох.

Інференс побудовано за принципом авторегресивної генерації. Модель отримує на вхід текстові токени і крок за кроком передбачує наступний аудіо-токен до появи спеціального токена [EOS] або досягнення ліміту (max_new_tokens=400). Для прискорення генерації використано механізм KV-cache. Отримані токени декодуються у wav-файл за допомогою FocalCodec.

Опис використаних підходів семпсування

Під час авторегресивної генерації аудіо-токенів було протестовано два підходи семпсування (вибору наступного токена з розподілу ймовірностей):

1. **Greedy Search:** стратегія, за якої на кожному кроці завжди обирається токен із максимальною ймовірністю (температура наближена до нуля). Цей метод є детермінованим і зазвичай генерує найбільш безпечні, але часто одноманітні або роботизовані послідовності.
2. **Top-K Sampling:** Метод контрольованої випадковості. Замість вибору одного найкращого токена, модель розглядає K (у нашому випадку $K=50$)

найбільш ймовірних токенів і здійснює випадкову вибірку серед них з урахуванням їхніх ймовірностей та заданої "температури" ($T=0.9$). Це дозволяє уникнути зациклень моделі та робить згенероване мовлення більш природним, варіативним та експресивним.

Таблиці метрик порівняння підходів семплування

Оцінка згенерованого аудіо (на прикладі тестового речення: "The quick brown fox jumps over the lazy dog.") проводилася за трьома метриками:

- CER (Character Error Rate): Частота помилок на рівні символів (менше краще). Виміряно за допомогою ASR-моделі Whisper.
- SECS (Speaker Encoder Cosine Similarity): Косинусна схожість голосу з референсним диктором (більше краще).
- UTMOS (UTokyo Mean Opinion Score): Оцінка загальної якості та природності звучання нейронною мережею (від 1 до 5, більше краще).

Стратегія семплування	CER (↓)	SECS (↑)	UTMOS (↑)
Greedy Search	0.841	0.573	4.147
Top-K (k=50, t=0.9)	0.841	0.795	3.776

Гіпотези й думки щодо отриманих результатів

На основі отриманих результатів можна зробити наступні висновки щодо працездатності пайплайну та якості моделі:

1. Пайплайн навчання налаштовано коректно. Протягом 10 епох функція втрат (train_loss) стабільно знизилася з ~ 6.15 до 0.818, що підтверджує здатність моделі до навчання.
2. Точність тексту (CER): Показник CER = 0.84 є високим (модель генерує лепет замість чітких слів). Гіпотеза: Даний результат є цілком закономірним для 10 епох навчання. Модель встигла засвоїти базову фонетичну структуру мови (генерує звуки, подібні до слів), але для вивчення точного мапінгу "текст -> звук" необхідно навчання із більшою кількістю епох.
3. Клонування голосу (SECS): Стратегія Top-K показала значно вищу здатність зберігати ідентичність цільового диктора

Гіпотеза: Жадібний пошук усереднює вибір, що призводить до втрати унікальних інтонацій та мікро-варіацій голосу. Внесення випадковості через Тор-К дозволяє нейромережі краще імітувати динамічний тембр людського голосу.

4. Акустична якість (UTMOS): Обидві стратегії показали несподівано високі результати (>3.7), проте Greedy виявився кращим (4.147).

Гіпотеза: Метрика UTMOS оцінює саме акустичну чистоту звуку, а не його лінгвістичний зміст. Нейронний кодек FocalCodec здатен синтезувати чистий аудіосигнал навіть із семантично неправильних токенів. Метод Greedy генерує акустично стабільний сигнал, тоді як Тор-К через свою креативність може іноді обирати токени, що створюють ледь помітні артефакти або шуми, трохи знижуючи оцінку.